



Executive Master « Data Engineering » (MSDE)

Projet du Module 5 : Machine Learning (ML)

Enseignant : Pr. Abdelhamid Fadil

Objectifs et consistance du projet ML :

L'objectif du projet ML est de mettre en pratique les notions traitées dans le cours en les appliquant sur des problématiques réelles à travers la mise en œuvre d'un pipeline ML complet allant de la présentation et la compréhension de la problématique au déploiement de la solution ML.

À l'issue de ce projet, vous serez capable de :

- Traduire un problème métier en tâche ML supervisée (régression ou classification).
- Conduire une analyse exploratoire rigoureuse et communiquer les insights clés.
- Construire un pipeline ML reproductible et robuste.
- Sélectionner, évaluer et optimiser le modèle le plus adapté à la problématique.
- Déployer une application de prédiction interactive sur Streamlit Cloud.

Chaque groupe (monôme ou binôme) est appelé à traiter l'une des problématiques citées dans la table suivante.

N°	Dataset	Type ML	Description	Target	Lien dataset
1	Prédiction du prix d'un billet d'avion	Régression	Ce dataset contient des données de réservation de vols issues du site EaseMyTrip, couvrant les liaisons entre les 6 principales villes de l'Inde. Il a été collecté sur cette plateforme utilisée par les voyageurs pour acheter des billets d'avion, avec pour objectif d'analyser les facteurs influençant le prix des billets et de développer un modèle de régression prédictif. Taille : 300 153 lignes	price : prix du billet d'avion	Kaggle
2	Prévision de la demande horaire de location de vélos en libre-service	Régression	Ce dataset combine des données historiques d'utilisation avec des données météorologiques afin de prévoir la demande horaire de location de vélos dans le programme Capital Bikeshare de Washington D.C. Taille : 10 886 lignes	count : nombre total de vélos loués par heure	Kaggle
3	Prédiction du prix de vente d'une voiture d'occasion	Régression	Ce dataset, issu de la plateforme indienne CarDekho, recense des annonces de voitures d'occasion avec leurs caractéristiques techniques et commerciales. Taille : 371 528 lignes	selling_price : prix de revente du véhicule	Kaggle

N°	Dataset	Type ML	Description	Target	Lien dataset
4	Prédiction du résultat d'analyse médicale d'un patient hospitalisé	Classification	Dataset synthétique simulant des dossiers hospitaliers de patients, incluant des informations démographiques, des données médicales et des données administratives. Taille : 10 000 lignes	Résultat du bilan médical du patient : Normal, Abnormal, ou Conclusive (3 classes)	Kaggle
5	Prédiction du défaut de remboursement d'un prêt immobilier (mortgage)	Classification	Ce dataset concerne des prêts immobiliers (mortgage) et vise à prédire si un emprunteur sera en défaut de paiement. Il contient une combinaison de variables démographiques, financières et contractuelles Taille : 148 670 lignes	Status : 1 si l'emprunteur est en défaut de paiement, 0 sinon	Kaggle
6	Détection de transactions bancaires frauduleuses	Classification / Détection d'anomalie	Dataset de transactions par carte de crédit effectuées en septembre 2013 par des porteurs de cartes européens. Pour des raisons de confidentialité, les features V1 à V28 sont les composantes principales obtenues par PCA. Seules les variables Time et n'ont pas subi cette transformation. Taille : 284 807 lignes	Class : 1 si la transaction est frauduleuse, 0 sinon	Kaggle

Etapas et barème de notation :

N°	Axe	Intitulé	Points
1	Compréhension de la problématique	- Présentation de la problématique en explicitant le rôle du ML dans l'étude du thème et en définissant clairement le problème métier et le traduire en tâche ML (régression ou classification). - Etat de l'art (étude bibliographique) synthétique présentant les différents approches et algorithmes ML utilisés pour le traitement de la problématique en question	3
2	Analyse exploratoire des données (EDA)	Compréhension des données, exploration des données (types des variables, spécification de la variable Target, corrélations, répartition statistique des variables, tendances...) avec commentaires et conclusions tirées de l'EDA	3
3	Pré-processing des données	Pré-processing des données (traitement des données manquantes, encoding, normalisation, outliers...) & Feature Selection avec commentaires et justification des choix effectués	3
4	Construction des modèles ML	Application des algorithmes ML (au moins 10 algorithmes à tester) avec la présentation des résultats de chaque algorithme (indicateurs d'évaluation, graphes de performance...)	3
5	Tuning des modèles candidats et choix du modèle final	- Choix de 3 modèles ML les plus adéquats (argumentation, indicateur d'évaluation...) puis tuning de ces modèles candidats (Comparer les performances avant/après tuning et analyser les gains obtenus. - Choix du modèle final avec la mention des résultats finaux du test de ce modèle (metrics finaux, vérifier l'absence d'overfitting, etc.).	3
6	Déploiement du modèle	- Sérialiser le modèle final et le pipeline complet avec pickle ou joblib (<u>Attention : N'oubliez pas d'intégrer dans le pipeline les prétraitements effectués sur les données avant leur injection dans le modèle ML</u>)	3

		- Développer une application Streamlit avec : saisie des features par l'utilisateur, affichage des données saisies par l'utilisateur, affichage de la prédiction, niveau de confiance (probabilité) - Déployer sur Streamlit Cloud et fournir l'URL publique. - Structurer le dépôt GitHub : requirements.txt, README.md, notebook.ipynb, rappor.pdf, app.py. - Le README doit contenir : description du projet, <u>lien vers l'app déployée</u>, captures d'écran.	
7	Présentation du projet et ergonomie de l'application web	2 pts seront réservés pour l'évaluation de la forme de la présentation du travail, du rapport et de la qualité des commentaires ainsi que de l'ergonomie de l'application web de déploiement du modèle	2
8	Bonus	Publication de l'application en utilisant flask sur la plateforme Render ou autre outil de déploiement	2

Outils à utiliser : Les participants ont le libre choix des outils et des librairies qu'ils souhaitent utiliser (scikit-learn, AutoGluon, knime...)

Deadline de remise du projet : Dimanche 31 mai 2026 à 23H

Livrables du projet :

Les livrables sont à déposer sur votre **espace public Github** (voir point 6 ci-dessus) contenant les livrables suivants ;

1. Rapport (pdf) décrivant le processus de mise en œuvre du projet ML en explicitant les étapes citées ci-dessus
2. Fichier notebook complet avec des commentaires traçant les différentes activités effectuées pour la réalisation du projet en donnant l'ensemble des résultats (traitement de données, construction des modèles, graphiques et métriques d'évaluation, choix effectués, graphiques...)
3. Fichier script python de votre application (app.py)
4. Fichier de sérialisation du pipeline (pickle ou joblib)

Livrable à déposer sur Teams (Espace « Devoirs ») :

Fichier texte (projet_ML_votreNom.txt) contenant :

- Lien de l'espace Github de dépôt des livrables
- Lien streamlit de l'application déployée

NB : Tout plagiat, utilisation d'un notebook public ou génération pure et simple du code par IA entraînera une note de 0.