



المدرسة الحسنية للأشغال العمومية
ተ፻፲፭ ተ፻፲፱፻፲፱ ፻፲፱፻፲፱ ፻፲፱፻፲፱
ECOLE HASSANIA DES TRAVAUX PUBLICS

RAPPORT DE PROJET MACHINE LEARNING

Prédiction du défaut de remboursement d'un prêt immobilier

MSDE7 - EHTP - Année 2025/2026

Réalisé par : Nabil MELLOUKI

Table des matières

INTRODUCTION :	3
1. Contexte et objectif.....	4
2. Données et problématique	4
3. Analyse exploratoire et qualité des données	4
4. Pre-processing et prévention du data leakage	4
5. Comparaison des modèles et top 3	5
6. Optimisation et choix du modèle final	5
7. Variables importantes et lecture métier	6
8. Déploiement et exploitation	6
9. Structure du projet	8
10. Conclusion :	9

INTRODUCTION :

Dans un contexte où la maîtrise du risque de crédit est un enjeu majeur pour les institutions financières, la prédiction du défaut de remboursement constitue un outil d'aide à la décision essentiel. Ce projet vise à construire un pipeline de machine learning capable d'estimer la probabilité de défaut d'un emprunteur à partir de variables démographiques, financières et contractuelles.

L'approche choisie suit une démarche complète : analyse exploratoire, préparation des données, comparaison de plusieurs algorithmes, optimisation des meilleurs modèles, puis mise en production via une application exploitable. L'objectif est d'obtenir un modèle robuste, interprétable et cohérent avec les contraintes métier du financement immobilier.

1. Contexte et objectif

Ce projet a été réalisé dans le cadre du module Machine Learning de la 7eme edition du master exécutif en Data Engineering à l'EHTP.

L'enjeu est de prédire le défaut de remboursement d'un prêt immobilier, afin d'aider la décision de valider ou non le crédit en se basant sur des dossiers clients.

Le problème est formulé comme une classification binaire :

- Status = 1 : si l'emprunteur est en défaut de paiement
- Status = 0 : sinon

L'objectif principal est de séparer et identifier les profils a risque et les profils sains, avec une bonne capacite de discrimination (AUC-ROC).

2. Donnees et problematique

- Source : [Kaggle - Loan Default Dataset](#)
- Taille : 148 670 lignes, 34 variables
- Nature des variables : démographiques, financières et contractuelles
- Cible : Status (classification binaire)

Le jeu de données est déséquilibré (environ 25% de défaut), ce qui impose de suivre des métriques robustes (AUC, F1, Recall, Précision) et d'intégrer une gestion du déséquilibré lors de l'entraînement.

3. Analyse exploratoire et qualité des données

L'EDA a permis de comprendre la structure des données, la distribution de la cible et les variables les plus informatives. Plusieurs visualisations ont été effectués : répartition de la cible, boxplots par statut, heatmap de corrélations et taux de défaut par groupes catégorielles.

Cette phase a mis en évidence des signaux métier forts autour de Credit_Worthiness, LTV, Credit_Score et dtir1. Elle a aussi révélé un point critique de qualité : certaines colonnes contenaient une quantité de valeurs manquantes anormalement liée à la classe cible, ce qui pouvait introduire un biais majeur dans l'apprentissage.

4. Pre-processing et prévention du data leakage

Le pre-processing a été conçu pour garantir un apprentissage fiable et reproductible.

Etapes appliquées :

1. Suppression de ID (variable non predictive).

2. Suppression des colonnes a fuite: rate_of_interest, Interest_rate_spread, Upfront_charges.
3. Remplacement des valeurs manquantes : médiane pour les variables numériques, mode pour les variables catégorielles.
4. Encodage des variables catégorielles via LabelEncoder.
5. Normalisation avec StandardScaler.
6. Découpage train/test 80/20 avec stratification.

La suppression du data leakage a été effectué afin d'éviter d'obtenir des performances artificiellement élevées et rapproche le comportement du modèle d'un cas réel de production.

5. Comparaison des modèles et top 3

Dix modèles ont été comparés sur le même protocole d'évaluation : Logistic Regression, KNN, Decision Tree, Random Forest, Gradient Boosting, AdaBoost, Extra Trees, Bagging, Naive Bayes et XGBoost.

Top 3 modeles (avant tuning, selon AUC):

1. **XGBoost** - AUC: **0.8949**
2. **Gradient Boosting** - AUC: **0.8936**
3. **Random Forest** - AUC: **0.8885**

Ces trois modèles sont des méthodes d'ensemble basées sur les arbres, ce qui confirme que les relations non linéaires et les interactions entre variables jouent un rôle important dans la prédiction du défaut.

6. Optimisation et choix du modèle final

Les 3 meilleurs modèles ont été optimisés par RandomizedSearchCV (10 itérations, CV=2, scoring ROC-AUC).

Résultats du tuning :

Modele	AUC avant	AUC apres	Gain
XGBoost	0.8949	0.8985	+0.0036
Gradient Boosting	0.8936	0.8972	+0.0037
Random Forest	0.8885	0.8928	+0.0042

Le **modèle final choisi est XGBoost** car il obtient la meilleure AUC après optimisation.

Modèle choisi :

Performances finales de XGBoost : - Accuracy : **0.8804** - F1-Score : **0.7494** - AUC-ROC : **0.8985** - Recall : **0.7257** - Precision : **0.7747**

Ce compromis est pertinent pour un contexte de risque crédit : le modèle conserve une bonne précision sur les dossiers prédits en défaut tout en récupérant une part importante des défaillants réels.

7. Variables importantes et lecture métier

L'analyse d'importance des variables du modèle final (XGBoost) montre que les facteurs les plus contributifs incluent notamment : lump_sum_payment, property_value, LTV, Neg_ammortization, submission_of_application, credit_type, loan_type, Credit_Worthiness, dtir1, business_or_commercial.

D'un point de vue métier, ces variables traduisent des dimensions classiques du risque : structure du financement, profil de remboursement, qualité de credit, et nature de la demande.

8. Déploiement et exploitation

Le pipeline complet est sérialisé dans pipeline_loan_default.pkl avec :

- le modèle final
- le nom du modèle
- le scaler
- les encodeurs
- les listes de features

Le projet a été déployé sur streamlit et render :

- Lien streamlit : <https://projet-ml-loan-default-msde7-mellouki.streamlit.app/>

← ↻ 🏠 🔒 <https://projet-ml-loan-default-msde7-mellouki.streamlit.app> 🔍 🌐 ⭐ 👤

Share ☆ ✎ 🔄



المدرسة الحسنية للأشغال العمومية
HECR الحسنية العامة | EDC, DBI, EX, XSG, XI
ECOLE HASSANIA DES TRAVAUX PUBLICS

Python 3.14.5

Features attendues: 29

> Feature names



Prediction du Defaut de Remboursement - Pret Immobilier

Projet Machine Learning - MSDE7 | Ecole Hassania des Travaux Publics

Application de prediction basee sur un modele de Machine Learning entraine sur 148 670 dossiers de prets.

Mode de saisie :

☒ Saisie manuelle ☐ Upload CSV

Caracteristiques du pret

Annee	Duree du pret (mois)	Garanti par
2019	360	home
Loan Limit	Amortissement negatif	Nombre d'unites
cf	not_neg	1U

← ↻ 🏠 🔒 <https://projet-ml-loan-default-msde7-mellouki.streamlit.app> 🔍 🌐 ⭐ 👤

Share ☆ ✎ 🔄



المدرسة الحسنية للأشغال العمومية
HECR الحسنية العامة | EDC, DBI, EX, XSG, XI
ECOLE HASSANIA DES TRAVAUX PUBLICS

Python 3.14.5

Features attendues: 29

> Feature names



Prediction du Defaut de Remboursement - Pret Immobilier

Projet Machine Learning - MSDE7 | Ecole Hassania des Travaux Publics

Application de prediction basee sur un modele de Machine Learning entraine sur 148 670 dossiers de prets.

Mode de saisie :

☐ Saisie manuelle ☒ Upload CSV

Upload d'un fichier CSV

Le fichier doit contenir les memes colonnes que le dataset d'entrainement (sans ID et Status).

Choisir un fichier CSV

📎 Upload 200MB per file • CSV

- Lien Render : <https://projet-ml-loan-default-msde7.onrender.com/>

The image displays two screenshots of a web application titled "Prediction du Defaut de Remboursement - Pret Immobilier". The application is built using Streamlit and is deployed on Render. The top screenshot shows the "Saisie manuelle" (Manual Input) form, which allows users to input loan characteristics. The bottom screenshot shows the "Upload CSV" form, which allows users to upload a CSV file for batch prediction.

Top Screenshot: Saisie manuelle

Caracteristiques du pret

Annee	Loan Limit	Genre
2024	cf	Male

Approbation anticipée	Type de pret	Objectif du pret
nopre	type1	p1

Credit Worthiness	Open Credit	Business/Commercial
11	nopc	nob/c

Montant du pret (\$) : Duree du pret (mois) : Amortissement negatif :

Bottom Screenshot: Upload CSV

Le fichier doit contenir les memes colonnes que le dataset d'entrainement (hors ID et Status).

Choisir un fichier : Aucun fichier n'a été sélectionné

Predire pour tous les dossiers


Projet ML MSDE7 - EHTP - Pr. Fadil - 2025/2026

9. Structure du projet

app.py : Application Streamlit (déploiement principal)
 flask_app.py : Application Flask (bonus Render)
 notebook.ipynb : Notebook complet du pipeline ML
 pipeline_loan_default.pkl : Pipeline sérialisé (modèle + scaler + encoders)
 Loan_Default.csv : Dataset
 requirements.txt : Dépendances Python
 Procfile : Configuration Render (gunicorn)
 templates/index.html : Template Flask

Lien du répertoire sur Git :

<https://github.com/melloukinabil/projet-ml-loan-default-msde7.git>



10. Conclusion :

Ce travail a permis de mettre en place un pipeline fiable pour la prédiction du défaut de prêt immobilier sur un jeu de données de grande taille. L'étude comparative des modèles, suivie d'un tuning cible, a montré que XGBoost est le meilleur modèle pour ce cas d'usage, avec une AUC-ROC de 0.8985 et des performances équilibrées sur la classe de défaut.

Au-delà des performances, le projet met en avant des choix méthodologiques déterminants, notamment la gestion du déséquilibre des classes et la suppression explicite du data leakage.